Completion di feature nel dataset Breast Cancer

Pipeline, regole di completamento e confronto PCA–SVD

Report basato su `completion_breast_cancer_matrix.ipynb`

10 ottobre 2026

Abstract

In questo esperimento si ricostruiscono valori nascosti di tre delle 30 feature numeriche del dataset *Breast Cancer Wisconsin Diagnostic* (569 osservazioni). Ogni cella delle tre colonne è occultata con probabilità 30% lasciando visibili le altre 27 feature. Nelle 50 celle del test set principale la regressione lineare matriciale completa usa 27 predittori comuni. La variante complete-case usa invece oggetti con tutti i target osservati. Sono stati implementati PCA e SVD che danno ricostruzioni equivalenti quando si usa la stessa regola di completion. I modelli vengono confrontati tra loro e con una baseline che rimpia le celle nascoste con la media della colonna. Si verifica infine la stabilità delle ricostruzioni rispetto a cinque maschere della validation con diverse probabilità di nascondere un valore.

1 Che cosa viene ricostruito

Ogni riga del dataset descrive un'osservazione tramite 30 misure numeriche. L'esperimento nasconde alcuni valori di tre feature e chiede ai metodi di stimarli usando quelli rimasti visibili. I valori originali delle celle nascoste sono conservati soltanto per verificare la qualità delle stime. Lo scopo del lavoro è valutare l'efficacia di diversi metodi di completamento dei dati e non predire la diagnosi.

Indichiamo con $X \in [0,1]^{n\times d}$ la matrice normalizzata e con x_i la sua riga i. La maschera M distingue le celle osservate da quelle nascoste come vedremo nella sezione 3. Tutti i metodi lasciano invariati i valori osservati, ma stimano quelli mancanti in modi diversi: la baseline usa la media della colonna, i regressori sfruttano le altre feature e PCA/SVD ricostruiscono la riga tramite componenti principali.

Il training serve ad apprendere medie, coefficienti e componenti. La validation serve per fare tuning degli hyperparametri e a scegliere il rango di PCA e SVD. Nel test si applicano le regole già scelte e si confrontano le stime con i valori nascosti. Questa separazione evita che i valori da valutare influenzino l'addestramento o la scelta del rango, rischiando di causare potenziale overfitting.

2 Oggetti, matrice e preparazione dei dati

Il notebook carica *Breast Cancer Wisconsin Diagnostic*. Mescola le 569 righe e rende riproducibile questa operazione tramite il fissaggio di un seed. Successivamente sono creati tre split disgiunti: 426 righe di training, 85 di validation e 58 di test (75%,15%,10%). Una funzione `MinMaxScaler` è calcolata *solo* sul training; per ogni colonna porta il minimo e il massimo del training a 0 e 1. Validation e test usano gli stessi parametri usati nel training e sono limitati a $[0,1]$ (Nota: tali valori possono eccedere l'intervallo, in tal caso viene applicata la funzione di clipping limitando l'intervallo a $[0,1]$ come nel dataset del training).

Per mostrare la *matrix representation*, la tabella **??** riporta sei delle 30 colonne e cinque righe del test set in $Y = O_M(X_{\text{test}})$, ovvero la matrice X_{test} osservata tramite la maschera M. Le sigle $f_1, f_2, f_3, f_4, f_5, f_6$ corrispondono rispettivamente alle features `mean_radius`, `mean_texture`, `mean_concavity`, `mean_concave_points`, `worst_radius` e `worst_texture`. Il punto interrogativo rappresenta un valore realmente nascosto alla regola di completion.

Tabella 1: Porzione osservata $Y = O_M(X_{\text{test}})$, normalizzata; "?" indica una coordinata non disponibile.

Riga	f_1	f_2	f_3	f_4	f_5	f_6
1	0,2314	0,2530	0,0893	0,1693	?	0,2497
2	0,3816	0,4812	?	0,4720	0,3337	0,5696
3	0,2837	0,2293	?	0,1497	?	0,2063
4	0,2142	0,2658	0,0653	0,1098	?	0,6477
5	0,3860	0,2354	?	0,4664	0,3871	0,4091

La parte della maschera associata alle righe della tabella è

$$M_{\{1,2,3,4,5\},\{1,2,3,4,5,6\}} = \begin{pmatrix} 1 & 1 & 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 1 & 1 \end{pmatrix}.$$

La rappresentazione completa X conserva i valori veri nelle celle che appaiono come "?" in Y; il test li usa solo come riferimento per il punteggio. Il valore vero, ad esempio, in riga 3 per `mean_concavity` è 0,0857, e per `worst_radius` è 0,1967.

3 Osservazione, maschere e protocollo di valutazione

La maschera binaria $M_s \in \{0,1\}^{n_s \times 30}$, con $s \in \{\text{train}, \text{val}, \text{test}\}$, vale 1 sulle celle osservate o 0 in quelle che nasconde. Definiamo

$$\mathcal{O}_s = \{(i,j) : M_{s,ij} = 1\}, \qquad \mathcal{H}_s = \{(i,j) : M_{s,ij} = 0\},$$
$$\mathcal{O}_i = \{j : M_{ij} = 1\}, \qquad \mathcal{H}_i = \{j : M_{ij} = 0\}.$$

Formalmente il mascheramento è $O_{M_s}(X_s) = M_s \odot X_s$. È importante però notare che una cella pari a zero può essere un valore valido, quindi il prodotto numerico da solo non identifica le celle assenti. La vista incompleta del codice rappresenta le celle nascoste con `NaN` e conserva la maschera. La regressione matriciale legge soltanto le 27 feature sempre osservate: i target mancanti non richiedono imputazione. La PCA iterativa inizializza invece le celle nascoste con le medie del training, per poter proiettare una riga numerica completa. La SVD stima i coefficienti latenti dalle sole coordinate osservate; il riempimento iniziale delle celle nascoste non influenza tale stima.

Tutti i metodi preservano le coordinate osservate:

$$\widehat{X}_{s,ij} = X_{s,ij} \qquad \text{per } (i,j) \in \mathcal{O}_s.$$

Nella PCA i valori osservati vengono ripristinati dopo ogni proiezione. Regressione matriciale e SVD scrivono direttamente soltanto nelle celle nascoste.

Soltanto le features in $T = \{\texttt{mean_radius}, \texttt{mean_concavity}, \texttt{worst_radius}\}$, ovvero quelle identificate sopra, sono state soggette all'occultamento. Per ogni riga e per ciascuna di queste tre colonne, una Bernoulli indipendente con probabilità $p = 0,30$ pone $M_{ij} = 0$. Le altre 27 colonne sono sempre visibili. Si tratta quindi di una *maschera casuale sulle celle, vincolata a tre colonne*. Nota che questo ci porta a nasconder il 3% del dataset come valore atteso. Una riga può contenere zero, una, due o tre celle nascoste. Per rendere gli esperimenti ripetitibili con la stessa maschera sono stati fissati dei seed.

Tabella 2: Numero di celle occultate con la maschera principale. La percentuale è riferita a tutte le 30 colonne.

Split	Righe	Celle totali	Celle nascoste	Quota globale
Training	426	12 780	353	2,76%
Validation	85	2 550	74	2,90%
Test	58	1 740	50	2,87%

Esistono due ruoli distinti delle maschere. M_{train} limita l'evidenza usata *per apprendere* le varianti mascherate di regressione lineare e Ridge; le varianti complete, la PCA, la SVD e le medie della baseline sono apprese dal training completo. M_{val} e M_{test} limitano ciò che il modello vede *durante l'uso* e definiscono le celle sulle quali è misurato l'errore. Per la scelta del rango per PCA/SVD si impiegano cinque maschere della validation sulle stesse tre feature, anche esse con seed fissato per garantirne la riproducibilita della sperimentazione.

Per ogni split del dataset, le metriche RMSE e MAE e R^2 sono calcolate sulle sole celle di $\mathcal{H}_s$ dopo il clipping delle predizioni a $[0,1]$. È importante notare che queste metriche non misurano l'errore sulle celle osservate, che per costruzione sono copiate esattamente.

4 Baseline: completion con la media

Per ogni feature j, la baseline apprende $\mu_j = \frac{1}{n=426} \sum_{i \in \text{train}} X_{ij}$ dal training dataset completo. La regola è

$$\widehat{X}_{ij} = \begin{cases} X_{ij}, & M_{ij} = 1, \\ \mu_j, & M_{ij} = 0. \end{cases}$$

La baseline non sfrutta le relazioni tra feature durante la previsione: ogni colonna nascosta riceve una costante appresa. Questa regola viene utilizzata anche per l'inizializzazione delle celle mancanti nella PCA iterativa. I regressori matriciali non utilizzano le medie per riempire i predittori.

Tabella 3: Medie usate nella baseline e numerosità osservate/nascoste. La media "solo osservate" è una statistica descrittiva; non è usata dai regressori matriciali.

Feature	μ_j completo	μ_j^{obs}	Train obs.	Train nasc.	Test obs.	Test nasc.
`mean_radius`	0,3474	0,3538	319	107	39	19
`mean_concavity`	0,2082	0,2036	301	125	41	17
`worst_radius`	0,2969	0,2915	305	121	44	14

La Tabella **??** mostra come la media μ_j per le varie features è molto vicina alla media μ_j^{obs} delle sole features osservate.

5 Regressione Matriciale multi-output

I tre target sono raccolti nella matrice delle risposte $Y \in \mathbb{R}^{n \times 3}$. La matrice comune dei predittori contiene le 27 feature sempre osservate. Anche quando un target è disponibile, non viene usato per prevedere gli altri target.

Sfruttiamo una funzione `StandardScaler` stimata sulle sole righe di training utilizzate dal modello per centrare i predittori del training e portarli a varianza 1. La previsione dei tre output è

$$\widehat{Y} = AW, \qquad W \in \mathbb{R}^{28 \times 3}.$$

Sia in nella Linear Regression classica sia in Ridge, ogni colonna di W contiene l'intercetta e i 27 coefficienti usati per prevedere una feature target. La Linear Regression classica stima questi parametri minimizzando Ordinary Least Squares (OLS):

$$\widehat{W} = \arg\min_W \|Y - AW\|_F^2,$$

Ridge aggiunge una penalizzazione L_2 sui coefficienti, lasciando le intercette non penalizzate.

$$\|Y - AW\|_F^2 + \alpha \|W_{1:,:}\|_F^2, \qquad \alpha = 1,$$

dove $W_{1:,:}$ indica tutte le righe dalla seconda in poi, ovvero W ma senza la prima riga, quindi l'intercetta, non è penalizzata. Il parametro α è fissato.

La variante *completa* usa tutte le 426 righe e i tre target originali del training mentre la variante *complete-case* usa lo stesso insieme di righe (quelle completamente osservate, ovvero la maschera ha tutti uni) per tutti gli output. Le numerosità per singola colonna della tabella **??** non sono quindi il numero di righe utilizzate da questa variante. La selezione complete-case è una scelta per ottenere una matrice Y interamente osservata. Questo non è un requisito generale della regressione multi-output ma Y completa viene usata a scopo sperimentale.

In validation e test entrambi i modelli leggono soltanto i 27 predittori osservati, senza imputazione. Calcolano insieme i tre output, applicano clipping a $[0, 1]$ alle stime e scrivono soltanto nelle celle target nascoste. Le coordinate osservate sono conservate esattamente. Il confronto fra completo e complete-case cambia il campione usato per stimare coefficienti e standardizzazione, non l'insieme delle feature di input.

Tabella 4: Confronto diretto delle quattro regole lineari sulle celle nascoste.

Regola	RMSE val.	MAE val.	RMSE test	MAE test
OLS matr. completo	0,0130	0,0082	0,0231	0,0116
OLS matr. complete-case	0,0140	0,0085	0,0518	0,0171
Ridge matr. completo	0,0127	0,0082	0,0226	0,0122
Ridge matr. complete-case	0,0144	0,0094	0,0357	0,0162

6 PCA e SVD

6.1 Training centrato e rango

La PCA è calcolata sul training completo mediante `sklearn.decomposition.PCA`. Separatamente, il notebook calcola esplicitamente la SVD del training centrato, $X_c = U\Sigma V^\top$. Le prime r direzioni principali della PCA individuano lo stesso sottospazio delle prime r colonne di V come si vede nelle performance dei due in Figura **??**. Il relativo proiettore è $P_r = V_r V_r^\top$. Le colonne di V_r sono le direzioni principali nello spazio delle feature. La ricostruzione ortogonale di una riga completa è $\widetilde{x} = \mu + (x - \mu)P_r$.

Le prime sei componenti trovate spiegano il 91,03% della varianza del training e soddisfano per prime la soglia descrittiva del 90% come visto in Fiugra **??**. Ventiquattro spiegano il 99,901% della varianza. Il rango per completion viene invece scelto minimizzando l'RMSE aggregato sulle celle nascoste di cinque maschere della validation, provando $r = 1, \ldots, 30$. Il minimo è $r = 24$ per entrambe le procedure come visto in Figura **??**. A $r = 6$ l'RMSE aggregato è 0,03777 per PCA e 0,03781 per SVD; a $r = 24$ è 0,01406 e 0,01405. La prima maschera della validation è quella delle tabelle principali; le altre quattro sostengono la scelta del rango, perciò l'RMSE aggregato può differire dall'RMSE della sola maschera principale.

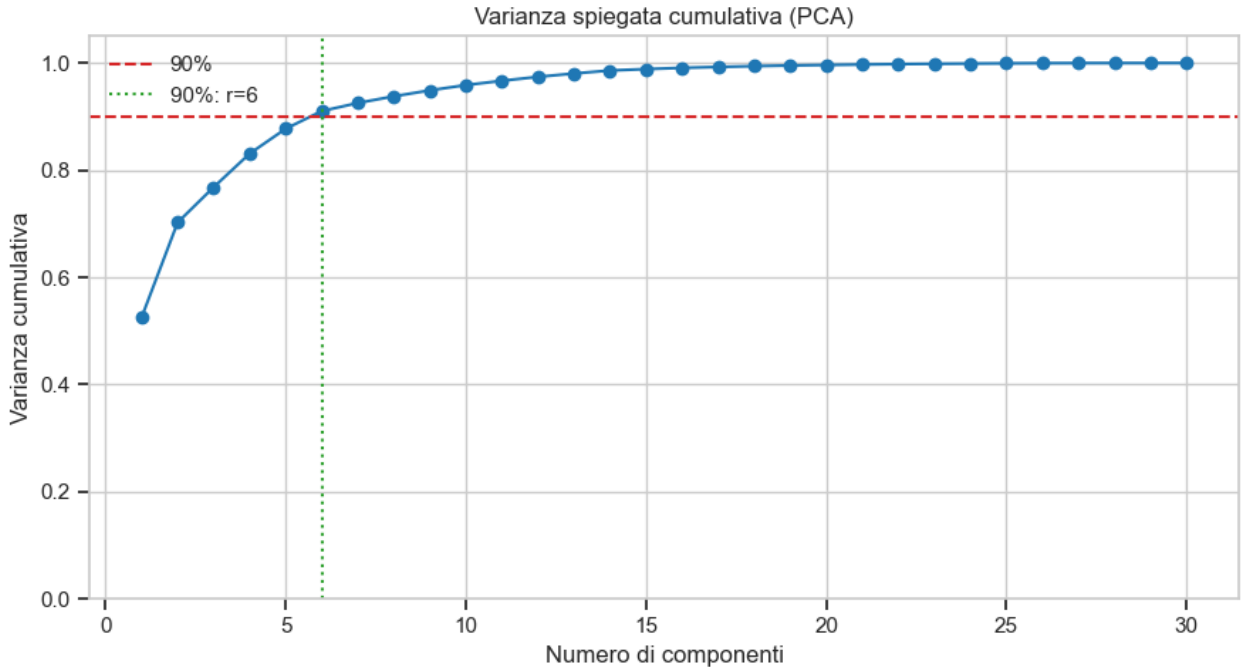


Figura 1: Rango rappresentativo del 90% della varianza

6.2 Regola PCA iterativa

La PCA del notebook parte da $x^{(0)}$, ovvero uno spazio a rango 1 monodimensionale, che sostituisce le coordinate nascoste con μ. Poi, per 30 iterazioni,

$$\widetilde{x}^{(t+1)} = \mu + (x^{(t)} - \mu)P_r, \qquad x_j^{(t+1)} = \begin{cases} x_j, & j \in \mathcal{O}_i, \\ \widetilde{x}_j^{(t+1)}, & j \in \mathcal{H}_i. \end{cases}$$

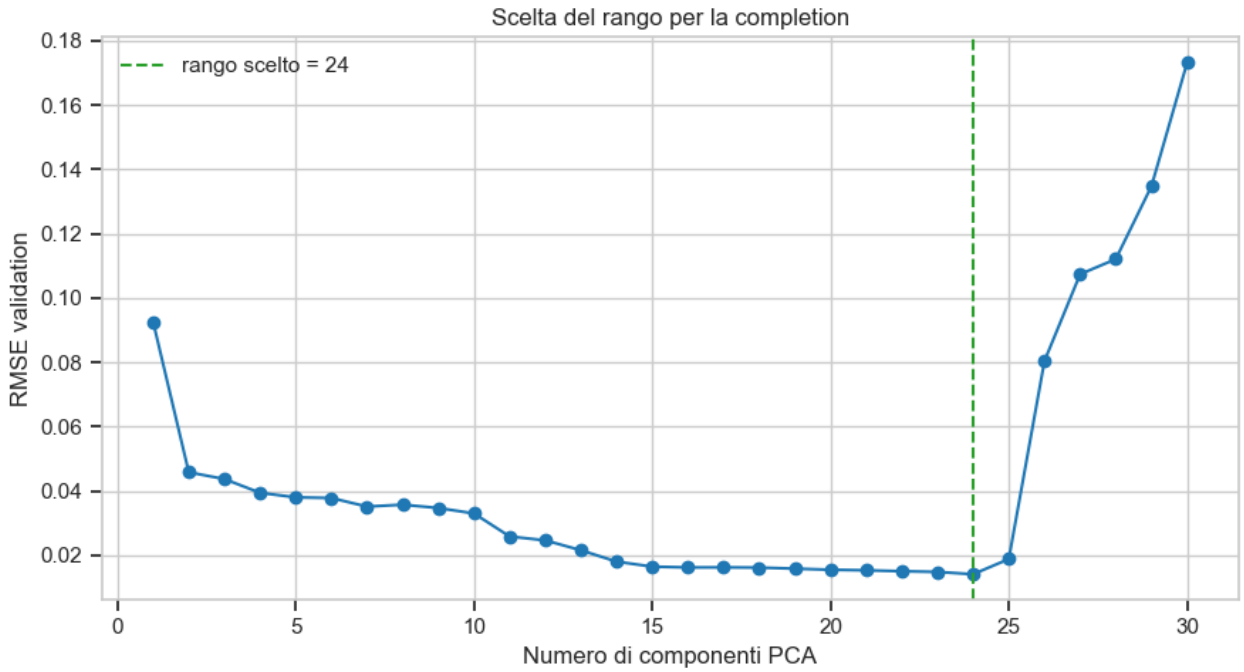


Figura 2: r=24 è il rango dello spazio trovato tramite PCA che minimizza RMSE

Le coordinate osservate sono quindi ripristinate a ogni passo. Dopo l'ultima iterazione, la ricostruzione è limitata a $[0, 1]$.

6.3 Regola SVD con adattamento sulle coordinate osservate

La SVD calcola per ogni riga incompleta un vettore di coefficienti usando soltanto $\mathcal{O}_i = \{j : M_{ij} = 1\}$:

$$\widehat{z}_i = \arg\min_{z \in \mathbb{R}^r} \|x_{i,\mathcal{O}_i} - \mu_{\mathcal{O}_i} - V_{r,\mathcal{O}_i} z\|_2^2 + \lambda \|z\|_2^2, \qquad \lambda = 10^{-3}.$$

Per $j \in \mathcal{H}_i$ pone $\widehat{x}_{ij} = \mu_j + (V_r \widehat{z}_i)_j$; per $j \in \mathcal{O}_i$ conserva x_{ij}. Il piccolo λ regolarizza il problema dei coefficienti latenti ed è distinto da $\alpha = 1$ della Ridge supervisionata. Anche qui si applica clipping finale a $[0, 1]$.

6.4 Equivalenza a parità di completion rule

Poiché PCA e SVD fattorizzano il medesimo X_c, le rispettive basi V_r^{PCA} e V_r^{SVD} individuano lo stesso sottospazio principale, eventualmente con segni o rotazioni ortogonali differenti. Se $V_r^{\text{PCA}} = V_r^{\text{SVD}} Q$ con $Q^\top Q = I$, allora i proiettori coincidono. Nella regola osservata-regolarizzata appena definita, il cambio di variabile $z' = Qz$ conserva sia il residuo sia la penalizzazione isotropa $\lambda \|z\|_2^2$. Ne segue la medesima ricostruzione anche sulle coordinate nascoste, a parità di media, rango, maschera, λ e clipping.

Il notebook verifica esplicitamente tale affermazione per *tutti* i ranghi 1-30 su validation e test, passando alla stessa funzione di completion come vediamo in Figura **??**. Nell'esecuzione riprodotta, la massima differenza registrata nei proiettori, nelle predizioni sulle celle nascoste e negli RMSE è 0 alla precisione numerica riportata. Per esempio, con la procedura comune l'RMSE test è 0,045196 per entrambe le basi a $r = 6$, e 0,023223 a $r = 24$.

È importante reiterare che questa equivalenza è vera se viene utilizzata *la stessa completion rule*. Nelle tabelle principali, PCA iterativa e SVD con adattamento regolarizzato usano regole diverse come visto in Figura **??**; piccole differenze di RMSE sono quindi coerenti con l'identità del sottospazio. Il fatto che la PCA sia centrata è essenziale: una SVD applicata alla matrice non centrata non avrebbe in generale le stesse direzioni della PCA qui utilizzata.

7 Risultati principali e confronto tra rango 6 e rango 24

Ricordiamo la dipperenza tra OLS matr/Ridge matr completo e complete-case:

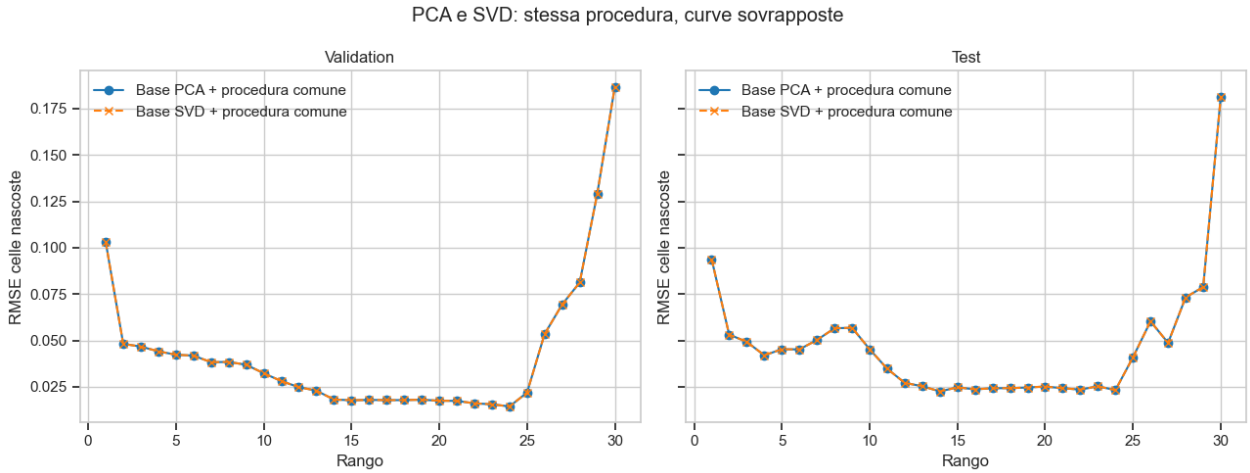


Figura 3: Performance uguali tra PCA e SVD alle quali viene applicata la stessa completion procedure. Questo risultato è prevedibile dato che SVD è stata computata con lo stesso dataset usato per PCA ma centrato.

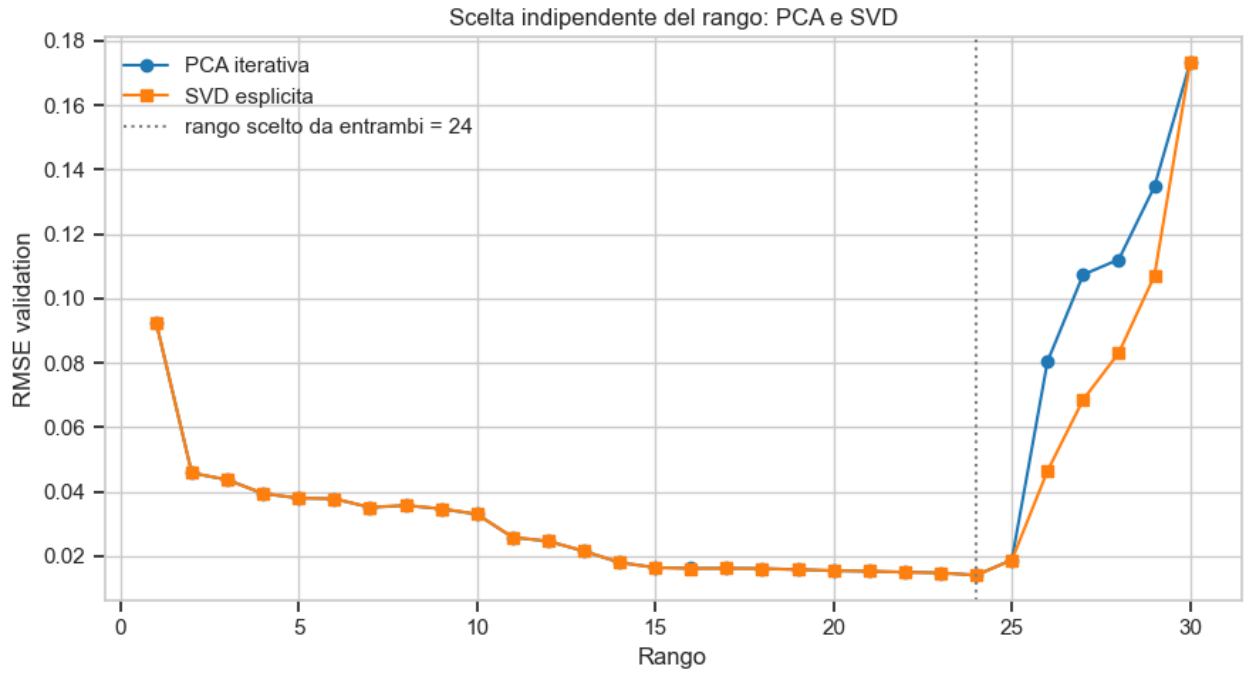


Figura 4: Due completion rules diverse possono portare il RMSA di PCA e SVD a divergere anche se il loro spazio vettorile è uguale

- **completo**: il modello è trainato sull'intero training set (anche se alcune entry sono NaN);
- **complete-case**: il modello è trainato sui soli oggetti completi.

Tabella 5: Tutti e nove i metodi sulla maschera principale: validation (74 celle) e test (50 celle). Rango 24 scelto su cinque maschere di validation; rango 6 fissato dal criterio descrittivo del 90%.

	Validation			Test		
Metodo	RMSE	MAE	R^2	RMSE	MAE	R^2
Media	0,1867	0,1412	0,0536	0,1814	0,1417	0,0799
OLS matr. completo	0,0130	0,0082	0,9954	0,0231	0,0116	0,9851
OLS matr. complete-case	0,0140	0,0085	0,9947	0,0518	0,0171	0,9251
Ridge matr. completo	0,0127	0,0082	0,9956	0,0226	0,0122	0,9858
Ridge matr. complete-case	0,0144	0,0094	0,9944	0,0357	0,0162	0,9644
PCA iterativa, $r = 24$	0,0144	0,0096	0,9943	0,0234	0,0131	0,9847
SVD esplicita, $r = 24$	0,0144	0,0096	0,9943	0,0232	0,0131	0,9849
PCA iterativa, $r = 6$	0,0418	0,0312	0,9525	0,0451	0,0323	0,9430
SVD esplicita, $r = 6$	0,0418	0,0312	0,9524	0,0452	0,0323	0,9429

Sulla maschera principale del test, il minimo RMSE fra i nove metodi è ottenuto da Ridge matriciale completo (0,02255). La PCA e la SVD (con metodologie di completion diverse) a rango 24 sono vicine (0,02336 e 0,02322), mentre il rango 6 produce 0,04515 e 0,04520: quasi due volte l'errore dei rispettivi modelli a rango 24. Sulla validation principale il rapporto è circa 2,9. La scelta $r = 6$ mantiene una forte compressione e il 91,03% della varianza, ma scarta direzioni che in questo problema risultano utili a ricostruire le tre feature occultate. La quota di varianza globale non rappresentano una misura diretta dell'errore sulle celle nascoste.

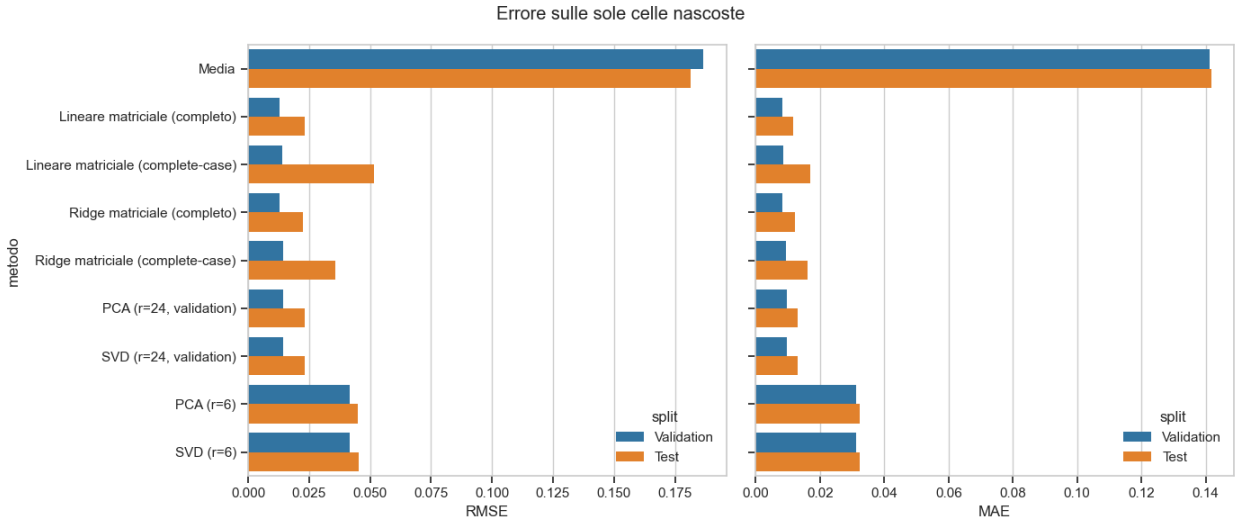


Figura 5: RMSE e MAE dei nove metodi sulle celle nascoste delle maschere principali.

7.1 Errore per feature e un esempio di ricostruzione

L'RMSE aggregato può nascondere difficoltà di completion per particolari features. Nel test, sono rappresentati 50 oggetti ma sono valutate solo 19 entry per `mean_radius`, 17 per `mean_concavity` e 14 per `worst_radius` a causa della maschera. La Tabella **??** mostra i valori per ciascun metodo.

8 Analisi di sensibilità presenti nel notebook

8.1 Cambiare il gruppo di feature target

Sono stati confrontati due gruppi di feature, uno che chiamiamo "distribuito" {`mean_radius`, `mean_concavity`, `worst_radius`} ovvero quello analizzato fin ora e un gruppo che chiamiamo "raggio" {`mean_radius`, `radius_error`, `worst_radius`}. Entrambe le prove generano una nuova maschera test (con seed fissato per riproducibilità) con 47 celle nascoste; per le varianti mascherate dei regressori si genera anche una nuova maschera train (con seed fissato per

Tabella 6: RMSE test per feature nascosta.

Metodo	`mean_radius`	`mean_concavity`	`worst_radius`
Media	0,1745	0,1705	0,2023
OLS matr. completo	0,0026	0,0391	0,0060
OLS matr. complete-case	0,0030	0,0884	0,0080
Ridge matr. completo	0,0031	0,0379	0,0076
Ridge matr. complete-case	0,0047	0,0600	0,0120
PCA iterativa, $r = 24$	0,0042	0,0393	0,0067
SVD esplicita, $r = 24$	0,0041	0,0391	0,0067
PCA iterativa, $r = 6$	0,0307	0,0612	0,0380
SVD esplicita, $r = 6$	0,0309	0,0612	0,0381

Tabella 7: Esempio di completion su due celle della medesima riga test. I valori veri sono mostrati solo per verificare l'errore.

Feature	Vero	Media	OLS comp.case.	Ridge comp.case.	PCA $r = 24$	SVD $r = 24$
`mean_concavity`	0,0857	0,2082	0,0890	0,0840	0,0986	0,0988
`worst_radius`	0,1967	0,2969	0,1994	0,1990	0,1946	0,1948

riproducibilità). I regressori sono riaddestrati sui tre target appropriati e sulle altre 27 feature come predittori comuni; Queste prove cambiano quindi il gruppo di feature da completare.

Tabella 8: RMSE test con due gruppi di feature occultate.

Metodo	Gruppo distribuito	Famiglia del raggio
Media	0,1770	0,1738
OLS matr. completo	0,0241	0,0229
OLS matr. complete-case	0,0372	0,0151
Ridge matr. completo	0,0206	0,0185
Ridge matr. complete-case	0,0273	0,0236
PCA iterativa, $r = 24$	0,0246	0,0301
SVD esplicita, $r = 24$	0,0245	0,0301
PCA iterativa, $r = 6$	0,0523	0,0501
SVD esplicita, $r = 6$	0,0523	0,0501

8.2 Cambiare la probabilità di occultamento

Mantenendo le tre feature target principali e i modelli già stimati, il notebook valuta $p = 10\%, 30\%, 50\%, 70\%$, ovvero la probabilità di occultamento delle feature target, con seed fissato. I dati di Figura **??** sono stati computati cambiano il seed della maschera, quindi i risultati del gruppo "distribuito" sono leggermente diversi da quelli della Figura **??**.

Tabella 9: RMSE test per probabilità (feature nascoste) di occultamento nelle tre colonne target.

Metodo	10% (17)	30% (49)	50% (91)	70% (127)
Media	0,1722	0,1697	0,1713	0,1761
OLS matr. completo	0,0087	0,0185	0,0163	0,0174
OLS matr. complete-case	0,0092	0,0203	0,0169	0,0341
Ridge matr. completo	0,0089	0,0182	0,0160	0,0172
Ridge matr. complete-case	0,0094	0,0181	0,0153	0,0243
PCA iterativa, $r = 24$	0,0100	0,0233	0,0201	0,0195
SVD esplicita, $r = 24$	0,0098	0,0233	0,0200	0,0194
PCA iterativa, $r = 6$	0,0268	0,0447	0,0415	0,0457
SVD esplicita, $r = 6$	0,0267	0,0447	0,0415	0,0457

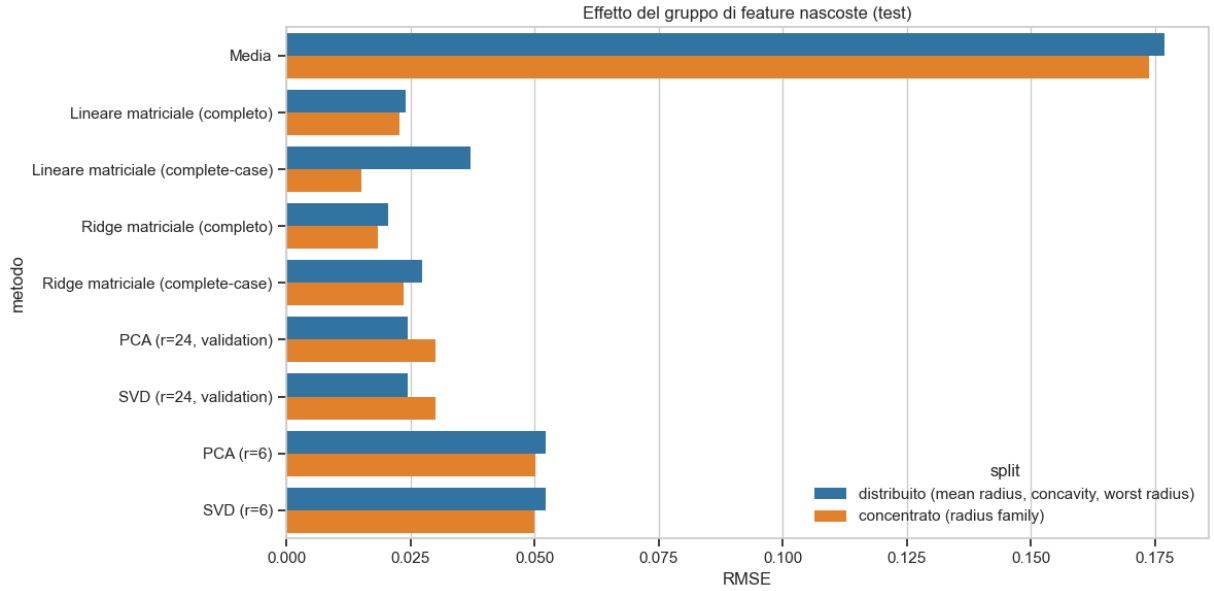


Figura 6: Sensibilità dell'RMSE al gruppo di feature nascoste. Figura originale del notebook.

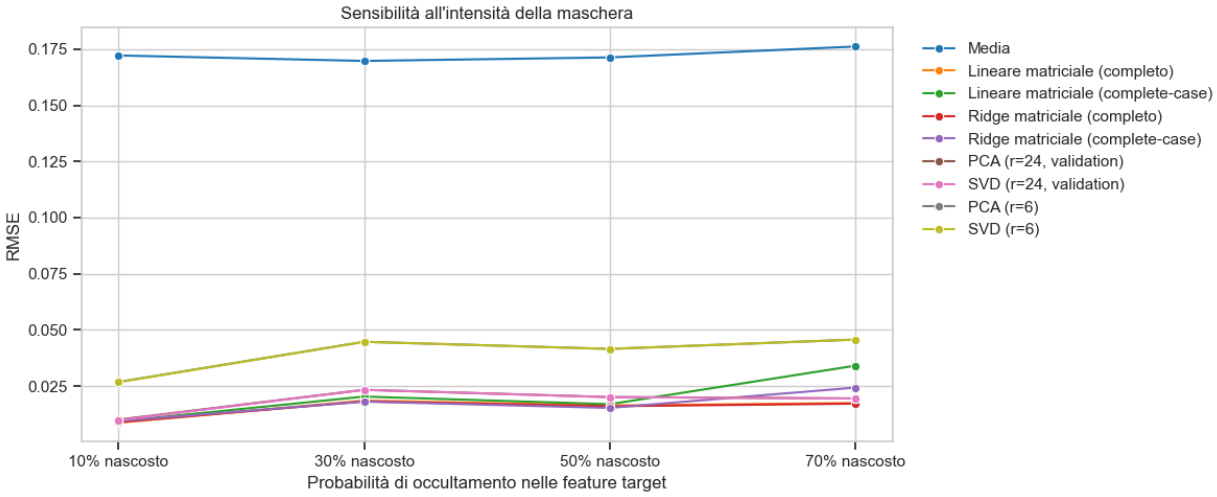


Figura 7: RMSE dei nove metodi per diverse probabilità di mascheramento delle feature target.

9 Conclusioni

Quale informazione rende prevedibili i valori nascosti? Le 27 feature sempre osservate contengono misure correlate di dimensione e forma: i regressori ne sfruttano la ridondanza e PCA/SVD stimano i coefficienti latenti dalle coordinate rimaste visibili. Sul test principale la media ha RMSE 0,1814; il minimo fra i nove metodi è Ridge matriciale (completo), con RMSE 0,0226. PCA/SVD a rango 24 ottengono circa 0,023, il rango 6 conserva il 91,03% della varianza, ma perde direzioni utili per questa completion. Le tre colonne non sono ugualmente facili da ricostruire: `mean_concavity` resta la più difficile anche se la completion è ad ogni modo di qualità.

Questi risultati riguardano il test set principale. Ripetere split e maschere, e occultare più colonne, permetterebbe di stimare la variabilità e di capire quanto la prestazione dipenda dal protocollo scelto. Questo approccio tuttavia non è stato usato.

10 Required check: SVD troncata e proiettori

Il controllo richiesto dalla consegna è eseguito al termine del notebook sulla matrice del training centrata, $X_c = X_{\text{train}} - \mathbf{1}\mu^{\mathsf{T}}$, dove μ contiene le medie delle feature del training. Si riutilizza la SVD $X_c = U\Sigma V^{\mathsf{T}}$ e si fissa $r = 6$, senza selezionare il rango sul test. Definiamo

$$X_r = U_r\Sigma_r V_r^{\mathsf{T}}, \qquad P_r^{(s)} = U_r U_r^{\mathsf{T}} \in \mathbb{R}^{n\times n}, \qquad P_r^{(f)} = V_r V_r^{\mathsf{T}} \in \mathbb{R}^{d\times d}.$$

Il primo proiettore agisce nello spazio delle osservazioni, il secondo nello spazio delle feature. La verifica confronta le quattro forme

$$P_r^{(s)} X_c \approx X_c P_r^{(f)} \approx P_r^{(s)} X_c P_r^{(f)} \approx X_r.$$

Tabella 10: Required check con $r = 6$: confronto di tutte le coppie di ricostruzioni. Lo scarto relativo è $\frac{\|A-B\|_F}{\|X_r\|_F}$; il massimo è calcolato sulle singole celle.

Confronto A vs B	$\|A - B\|_F$	Scarto relativo	Max. assoluto
$P_r^{(s)}X_c$ vs $X_cP_r^{(f)}$	$2{,}287 \cdot 10^{-14}$	$1{,}406 \cdot 10^{-15}$	$2{,}304 \cdot 10^{-15}$
$P_r^{(s)}X_c$ vs $P_r^{(s)}X_cP_r^{(f)}$	$1{,}473 \cdot 10^{-14}$	$9{,}059 \cdot 10^{-16}$	$1{,}332 \cdot 10^{-15}$
$P_r^{(s)}X_c$ vs X_r	$1{,}524 \cdot 10^{-14}$	$9{,}371 \cdot 10^{-16}$	$1{,}332 \cdot 10^{-15}$
$X_cP_r^{(f)}$ vs $P_r^{(s)}X_cP_r^{(f)}$	$1{,}824 \cdot 10^{-14}$	$1{,}122 \cdot 10^{-15}$	$2{,}331 \cdot 10^{-15}$
$X_cP_r^{(f)}$ vs X_r	$1{,}955 \cdot 10^{-14}$	$1{,}202 \cdot 10^{-15}$	$2{,}331 \cdot 10^{-15}$
$P_r^{(s)}X_cP_r^{(f)}$ vs X_r	$1{,}355 \cdot 10^{-14}$	$8{,}331 \cdot 10^{-16}$	$7{,}772 \cdot 10^{-16}$

Tutti i confronti superano gli assert con tolleranze assoluta e relativa 10^{-10}. Il massimo scarto per cella è circa $2{,}33 \cdot 10^{-15}$: le quattro forme coincidono entro gli errori di arrotondamento numerico.

Tabella 11

Proiettore	m	Rango	$\|P^2 - P\|_F$	$\|P - I_m\|_F$
$P_r^{(s)}$ (osservazioni)	426	6	$2{,}117 \cdot 10^{-15}$	20,493902
$P_r^{(f)}$ (feature)	30	6	$3{,}398 \cdot 10^{-15}$	4,898979

Perché i proiettori non sono l'identità?

Dimostrazione. Formalmente la motivazione per il quale l'equazione

$$P_r^{(s)} X_c = X_c P_r^{(f)} = P_r^{(s)} X_c P_r^{(f)} = X_r$$

è soddisfatta è che possiamo riscrivere il tutto come

$$P_r^{(s)} U\Sigma V^T = U\Sigma V^T P_r^{(f)} = P_r^{(s)} U\Sigma V^T P_r^{(f)} = X_r$$

è importante a questo punto un osservazione: $U_r^T U = \begin{bmatrix} I_r & 0 \end{bmatrix}$ e $V_r^T V = \begin{bmatrix} I_r \\ 0 \end{bmatrix}$. Questo accade perchè possiamo scrivere U distinguendo i vettori di base principali dagli altri, quindi $U = \begin{bmatrix} U_r, U_{\text{rest}} \end{bmatrix}$, quindi $U_r^T U_r = U_r^T \begin{bmatrix} U_r & U_{\text{rest}} \end{bmatrix} = \begin{bmatrix} U_r^T U_r & U_r^T U_{\text{rest}} \end{bmatrix} = \begin{bmatrix} I_r & 0 \end{bmatrix}$ e $U_r^T U_{\text{rest}} = 0$ perchè i vettori sono ortonormali, quindi i prodotti scalari danno 0. Con un ragionamento analogo si ottiene $V_r^T V = \begin{bmatrix} I_r \\ 0 \end{bmatrix}$. Quindi:

$$\begin{aligned} P_r^{(s)} X_c &= U_r U_r^T U\Sigma V^T \\ &= U_r \begin{bmatrix} I_r & 0 \end{bmatrix} \Sigma V^T \\ &= U_r \Sigma_r V_r^T = X_r \end{aligned}$$

e

$$\begin{aligned} X_c P_r^{(f)} &= U\Sigma V^T V_r V_r^T \\ &= U\Sigma \begin{bmatrix} I_r \\ 0 \end{bmatrix} V_r^T \\ &= U_r \Sigma_r V_r^T = X_r \end{aligned}$$

infine possiamo scrivere

$$P_r^{(s)} X_c P_r^{(f)} = X_r P_r^{(f)} = U_r \Sigma_r V_r^T V_r V_r^T$$

ma $V_r^T V_r = I_r$, quindi otteniamo

$$P_r^{(s)} X_c P_r^{(f)} = U_r \Sigma_r V_r^T = X_r$$

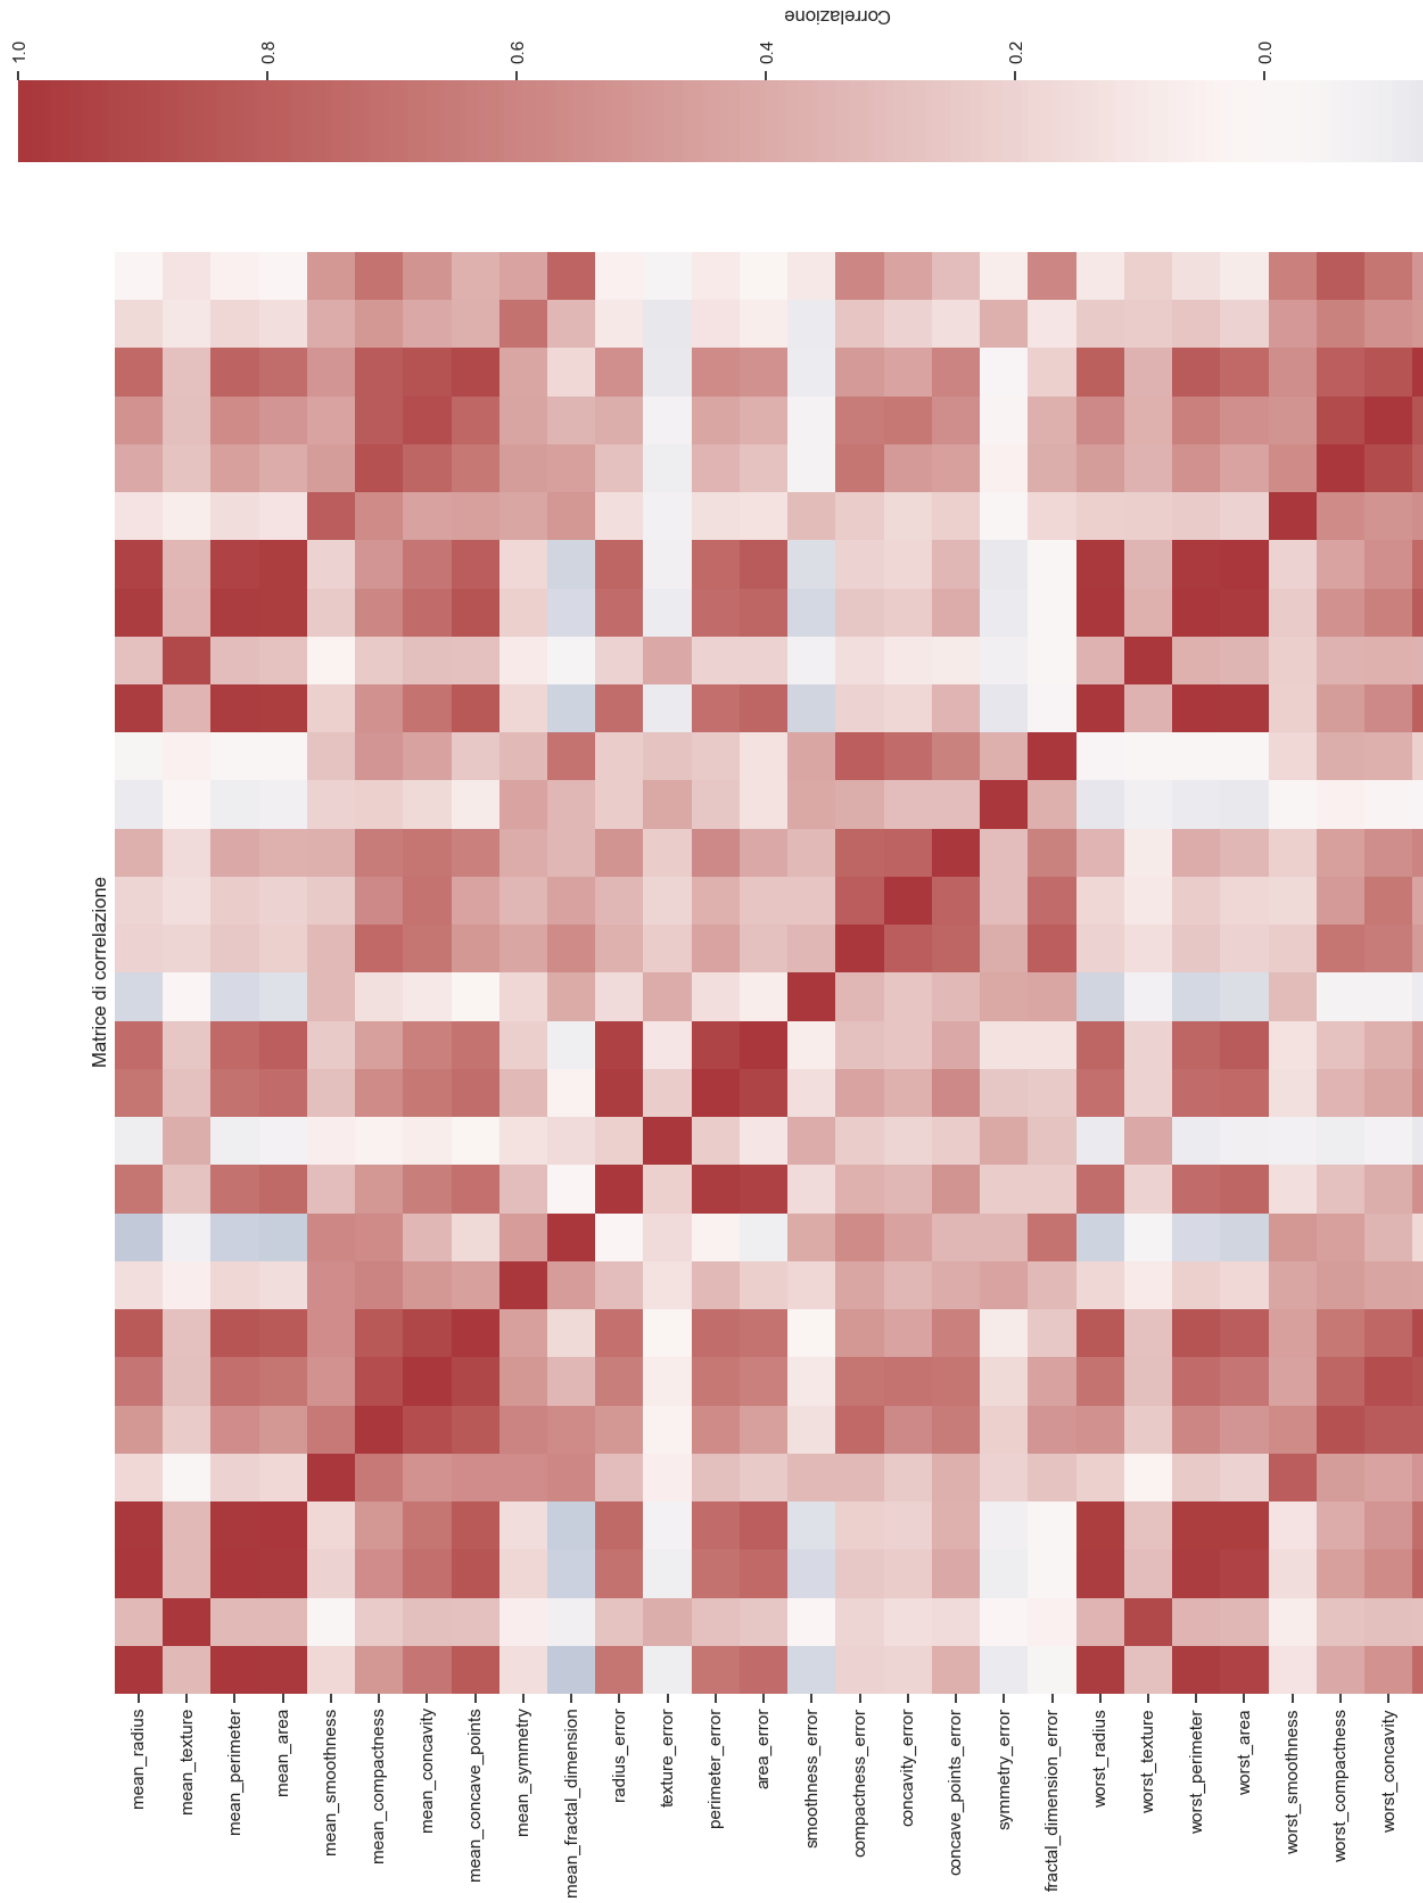
il che dimostra che tutte e quattro le forme coincidono, ovvero

$$P_r^{(s)} X_c = X_c P_r^{(f)} = P_r^{(s)} X_c P_r^{(f)} = X_r.$$

□

Fonti e riproducibilità

I numeri e le figure derivano dall'esecuzione salvata di `completion_breast_cancer_matrix.ipynb`. Le tabelle supplementari sono ricostruite da `report_assets/build_report_data.py`; i CSV in `report_assets/` conservano i valori non arrotondati. Tutte le metriche si riferiscono alla scala normalizzata $[0, 1]$.


Correlazione
1.0
0.8
0.6
0.4
0.2
0.0
Matrice di correlazione
mean_radius
mean_texture
mean_perimeter
mean_area
mean_smoothness
mean_compactness
mean_concavity
mean_concave_points
mean_symmetry
mean_fractal_dimension
radius_error
texture_error
perimeter_error
area_error
smoothness_error
compactness_error
concavity_error
concave_points_error
symmetry_error
fractal_dimension_error
worst_radius
worst_texture
worst_perimeter
worst_area
worst_smoothness
worst_compactness
worst_concavity

A Interazioni con l'AI

L'approccio con AI è stato di tipo agent-oriented. Oltre le query eseguite sono stati usati anche i vari comandi messi a disposizione dai tool per la scelta dei modelli più appropriati, impostare goal, condividere files, ... Il contesto degli agenti è sempre lo stesso, l'intero accesso alla cartella contenente notebook, richiesta dell'homework e il libro di testo vincolato ai soli primi quattro capitoli (per coerenza nei formalismi).

1. **Prima struttura del notebook.** *Domanda:* Devo consegnare il progetto descritto in "homework_ch1_4_completion 1.pdf".

   La mia idea è quella di sfruttare il dataset breast_cancer di scikitlearn. Le nozioni teoriche per supportare il problema si trovano in "CompletionAgent_1.0.pdf".

   Produci un notebook ricco di descrizioni dettagliate riguardo i passi intrapresi e le motivazioni in italiano e con anche definizioni tecniche.

   Struttura del notebook:

   - Importazione della matrice nxd.

   - Proponi un analisi della matrice prodotta, quindi media, stdandard deviation, min, max.

   - Plot della correlation matrix.

   - Dividi la matrice in Training, Validation e Test set (75,15,15). Normalizza il training set.

   - Su Validation set e Test set introduci una maschera M in grado di nascondere alcune entry. Fai in modo che è possibile controllare la matrice. È importante introdurre la possibilità di gestire la percentuale di features nascoste e quali features sono soggette alla maschera.

   - Proponi un semplice mean completion rule (baseline), ovvere sostituisci il valore non osservato con il valore della media di tale feature (ovvero la media della colonna).

   - Proponi una nuova completion rule che sfrutta la regressione lineare.

   - Confronta i risultati ottenuti dalla baseline e dalla linear regression.

   - Riemi ora i dati mancanti tramite media computa PCA e tramite la low-dimension structure fai completion delle feature nascoste.

   Produci plot, tabelle e usa strumenti di visualizzazione che ritieni appropriati per analizzare i dati, relazioni e qualità dei modelli. *Esito:* L'agente ha prodotto un notebook di disceta qualità. È inutile nascondere che sono state necessarie correzioni e aggiunte, come ad esempio nel caso della scelta del rango della PCA dato che non è stato esplicitato un criterio specifico nella mia query.

2. **Prima revisione del report.** *Domanda:* Analizza il notebook "completion_breast_cancer_completion.ipynb", verifica problemi nella metodologia, struttura o incoerenza di possibili risultati. Verifica che non sono presenti ridondanze. Proponi migliorie se necessarie *Esito:* Questa query è stata eseguita in diverse fasi durante la produzione del notebook. Ha proposto migliorie e/o errori tecnici. Il progetto è stato ritenuto da me completato quando sono stato soddisfatto della qualità del notebook e l'agente ha proposto solo migliorie marginali. Nota che questa tipologia di query (analisi del lavoro prodotto) sarebbe potuta essere abusata tramite il comando goal, che avrebbe potuto portare a una revisione infinita del notebook e di conseguenza ad un consumo smisurato di token. Ho quindi deciso di non abusare di questo comando e di limitarmi a una sola revisione finale.

3. **Completo vs Complete case.** *Domanda:* Per i modelli OLS e Ridge aggiungi una variante trainata su un dataset composto solo dagli oggetti completamente osservati ovver quelli con tutti i valori disponibili (nessuna entry mancante nella matrice). Aggiungi questo modello nei vari confronti (tabelle, plot) del notebook. *Esito:* L'agente ha prodotto risultati di qualità. In questo caso è stata necessaria solo una revisione del lavoro dato prodotto dall'agente data la qualità del lavoro prodotto.